

In The name of God




$$T = XW$$

$$W = [v_1 \ v_2 \ \dots \ v_k]$$

$$Ax = b$$


$$x \in \mathbb{R}^n$$



LINEAR ALGEBRA FINAL PROJECT

PCA: DISCOVERING THE ESSENCE OF DATA

Turning High-Dimensional Data
into Insight




$$C = \frac{1}{m-1} X^T X$$

Covariance Matrix

$$C v_i = \lambda_i v_i$$

$$B = X - 1\mu^T$$

5	0	4	1	9
3	8	6	2	7
4	1	5	9	0
7	3	1	8	6
2	6	0	4	3



GILBERT STRANG
Linear Algebra
and its Applications

GOLUB & VAN LOAN
Matrix Computations

HORN & JOHNSON
Matrix Analysis

KEY CONCEPTS

- ✓ Vector Spaces
- ✓ Linear Transformations
- ✓ Orthogonality
- ✓ Eigenvalues & Eigenvectors
- ✓ Rank & Null Space
- ✓ Change of Basis
- ✓ Matrix Decompositions
- ✓ Dimension Reduction

THE JOURNEY

Data
Centering
Covariance Matrix
Eigen Decomposition
Change of Basis
Lower Dimension
Reconstruction & Insight

GRAM-SCHMIDT

$$q_1^T q_j = \delta_{ij}$$

$$QR$$
$$A = QR$$
$$R = Q^T A$$
$$Q^T Q = I$$

$$Q^T Q = I$$
$$(Ax = b)$$
$$\|x\|$$

Behind every
algorithm
is beautiful
linear algebra.

Professor :
Dr. MirHossein Dezfoulan

Spring_2026

Teaching Assistant Team :
Nima Makhmali – Matin AmirPanahFar
Kiarash KamraniKia – Alireza Sagharichian

سرآغاز

درود!

به مرحله آخر درس جبرخطی خوش آمدید

ما در طول این ترم با مفاهیم متعددی در جبر خطی آشنا شدیم:

- بردارها و ماتریس‌ها
- دستگاه‌های معادلات خطی
- استقلال خطی
- فضاهای برداری
- رتبه و فضای بوج
- تبدیلهای خطی
- تعامد
- تجزیه‌های ماتریسی
- مقادیر و بردارهای ویژه
- قطری سازی

در بسیاری از مواقع شما این مفاهیم را به صورت مجموعه‌ای از تعاریف و قضایا می‌بینید و ممکن است این سؤال برای شما ایجاد شود که :

این مفاهیم در دنیای واقعی چه کاربردی دارند؟

هدف این پروژه پاسخ به همین سؤال است. (:

در این پروژه می‌خوایم ببینیم چطوری همه ی مباحثی که خوانده شد کنار هم قرار می‌گیرند و یک ابزار واقعی در هوش مصنوعی می سازند.

سناریو

قرار است دقیقاً چه کاری انجام دهیم؟

در این پروژه شما قرار نیست فقط یک الگوریتم را اجرا کنیم. قرار است ببینید مفاهیمی که در طول ترم یاد گرفتیم مثل فضای برداری، رتبه، بردارهای ویژه، تغییر پایه و تعامد چگونه در یک کاربرد واقعی در هوش مصنوعی کنار هم قرار می‌گیرند و یک ابزار قدرتمند می‌سازند.

الگوریتمی که روی آن کار می‌کنیم تحلیل مؤلفه‌های اصلی (PCA) نام دارد.

این الگوریتم یکی از پایه‌ای‌ترین روش‌های کاهش بُعد در یادگیری ماشین است.

کاهش بعد یعنی اینکه داده‌هایی که تعداد زیادی ویژگی دارند (مثلاً یک تصویر با ده‌ها یا صدها پیکسل)، به شکلی نمایش داده شوند که با تعداد ویژگی‌های کمتری تقریب خوبی از آنها داشته باشیم.

هدف این پروژه این است که شما این الگوریتم را از صفر و با تکیه بر مفاهیم جبر خطی پیاده‌سازی و تحلیل کنید. در پایان پروژه باید بتوانید توضیح دهید:

- داده‌ها از دید جبر خطی چه هستند؟
- فضای برداری داده‌ها چیست؟
- چرا داده‌ها باید مرکز شوند؟
- ماتریس کوواریانس چه اطلاعاتی را در خود نگه می‌دارد؟
- بردارهای ویژه چه معنایی دارند؟
- تغییر پایه در PCA چگونه اتفاق می‌افتد؟
- کاهش بعد دقیقاً به چه معناست؟
- رتبه و فضای یوچ چه نقشی در این فرآیند دارند؟
- چرا تعامد یکی از کلیدی‌ترین مفاهیم در PCA است؟

فرض کنید عضو یک تیم توسعه هوش مصنوعی هستید.

این تیم مجموعه‌ای از تصاویر دست‌نویس اعداد را در اختیار دارد و قصد دارد از آن‌ها برای ساخت مدل‌های یادگیری ماشین استفاده کند.

اما یک مشکل وجود دارد:

هر تصویر دارای تعداد 64 ویژگی است و نگهداری و پردازش این حجم از داده‌ها هزینه‌بر است.

سؤال اصلی این است :

آیا می‌توان تصاویر را با تعداد بسیار کمتری از ویژگی‌ها نمایش داد، بدون اینکه اطلاعات مهم آن‌ها از بین برود؟

برای پاسخ به این سؤال از یکی از مهم‌ترین ابزارهای جبر خطی و یادگیری ماشین استفاده خواهیم کرد:

Principal Component Analysis (PCA)

PCA یکی از مشهورترین روش‌های کاهش بعد در علم داده، یادگیری ماشین، پردازش تصویر و هوش مصنوعی است.

اما هدف این پروژه صرفاً اجرای یک الگوریتم آماده نیست.

هدف این است که مشاهده کنید چگونه مفاهیمی که در طول ترم آموخته‌ایم، در کنار یکدیگر قرار می‌گیرند و یک ابزار واقعی برای تحلیل داده می‌سازند.

در پایان پروژه باید بتوانید توضیح دهید:

- داده‌ها از دید جبر خطی چه هستند؟
- فضای برداری داده‌ها چیست؟
- چرا باید به داده‌ها مرکزیت بدهیم؟
- ماتریس کوواریانس چه اطلاعاتی را در خود نگه می‌دارد؟
- بردارهای ویژه چه معنایی دارند؟
- تغییر پایه در PCA چگونه اتفاق می‌افتد؟
- کاهش بعد دقیقاً به چه معناست؟
- رتبه و فضای پوچ چه نقشی در این فرآیند دارند؟
- چرا تعامد یکی از کلیدی‌ترین مفاهیم در PCA است؟

پروژه بدون قانون میشود ؟

قوانین، ساختار و نحوه تحویل پروژه

ساختار پروژه:

پروژه از دو بخش تشکیل شده است:

- بخش اصلی (اجباری) : شامل مراحل 1 تا 10 ، پیاده سازی کامل و تحلیل دقیق این بخش ها برای کسب نمره کامل پروژه (100٪) الزامی است.
- بخش اختیاری (امتیازی) : این بخش دارای نمره تشویقی است. انجام ندادن آن تأثیری بر نمره اصلی شما نخواهد داشت، اما برای دانشجویان علاقه مندی که به دنبال چالش بیشتر و کسب نمره مازاد هستند، فرصت فوق العاده ای است.

زبان برنامه نویسی : زبان **Python** به دلیل داشتن ابزارهای ماتریسی قدرتمند رایج تر هست.

کتابخانه مجاز :

numpy برای عملیات ماتریسی
matplotlib برای رسم نمودار
sklearn.datasets فقط برای بارگذاری داده

توجه توجه :

استفاده از **sklearn.decomposition.PCA** یا هر تابع آماده ای که مستقیماً PCA را اجرا کند ممنوع است.

برای محاسبه مقادیر ویژه روی ماتریس متقارن، مجاز به استفاده از :

numpy.linalg.eigh

استفاده کنید.

هدف این است که منطق ریاضی الگوریتم را خودتان پیاده سازی و درک کنید، نه اینکه فقط یک تابع آماده را اجرا کنید.

قوانین کار تیمی و امانتداری علمی :

- انجام این پروژه به صورت فردی یا در تیم‌های حداکثر **دو نفره** مجاز است.
- قانون هوش مصنوعی :
ما در عصر **AI** زندگی می‌کنیم!
استفاده از ابزارهای هوش مصنوعی (مثل ChatGPT, Claude, Copilot و...) برای یادگیری مفاهیم ریاضی، دیباگ کردن کد و دریافت راهنمایی کاملاً مجاز است.
اما!!!
کد نهایی و گزارش تحلیلی باید دست‌رنج ذهن **خودتان** باشد.
تولید کورکورانه کد توسط هوش مصنوعی بدون درک منطق آن، پذیرفته نیست.
شما باید بتوانید خط به خط کدتان را توضیح دهید و از آن دفاع کنید.
- هرگونه کپی‌برداری از پروژه سایر تیم‌ها **تخلف آموزشی** محسوب شده و نمره کل پروژه برای هر دو تیم (کپی‌کننده و کپی‌دهنده) **صفر** لحاظ خواهد شد.

جلسه دفاع ارزیابی :

برای اطمینان از یادگیری عمیق شما و بررسی صحت عملکرد تیم‌ها، پس از تحویل پروژه یک جلسه ارائه و دفاع کوتاه برای تمامی تیم‌ها برگزار خواهد شد.
آمادگی برای تحلیل کدهای نوشته شده و پاسخ به سوالات مفهومی در این جلسه الزامی است.

زمان و نحوه تحویل :

- **ددلاین نهایی** : مهلت انجام پروژه از زمان انتشار این سند تا پایان روز **16 مرداد ماه 1405** خواهد بود.
- **بستر تحویل** : فایل‌های نهایی پروژه (شامل کدهای برنامه و فایل گزارش PDF) باید در «**سامانه درس‌افزار**» در ماژول اختصاص داده شده بارگذاری شوند.
- نوشتن گزارش برای پروژه و بررسی آزمایش‌ها **اجباریست**.
- **نکته بسیار مهم برای تیم‌های دو نفره** :
حتی در صورت انجام گروهی کار، هر **دو عضو تیم** موظف هستند فایل‌های یکسان پروژه را به صورت مجزا در بِنل کاربری خود در سامانه بارگذاری کنند.
عدم آپلود فایل توسط هر یک از اعضا، به منزله عدم تحویل پروژه برای آن فرد تلقی خواهد شد.

یک نکته مهم: ویژگی (Feature) چیست؟

قبل از ورود به بحث جبر خطی، باید بدانیم «ویژگی» دقیقاً چیست.
در علم داده:

• نمونه (Sample) یک شیء یا مشاهده از داده‌هاست.
• ویژگی (Feature) یک عدد قابل اندازه‌گیری است که آن نمونه را توصیف می‌کند.

به زبان ساده:
هر نمونه با چند عدد توصیف می‌شود، و هر کدام از آن عددها یک ویژگی است.

مثال 1: تصویر

یک تصویر 8×8 از عدد «5» را در نظر بگیرید.
هر پیکسل یک عدد دارد که میزان روشنایی آن را نشان می‌دهد (مثلاً بین 0 تا 16).
پس:

- هر تصویر = یک نمونه
 - هر پیکسل = یک ویژگی
 - در این مثال: $64 \text{ پیکسل} \rightarrow 64 \text{ ویژگی}$
- یعنی هر تصویر را می‌توان به صورت یک بردار 64 بعدی در نظر گرفت.

مثال 2: داده جدولی

در پیش‌بینی قیمت خانه:

- هر خانه = یک نمونه
- متراژ، تعداد اتاق، سن ساختمان، فاصله تا مرکز شهر = ویژگی‌ها
- قیمت = برچسب (Label)

ارتباط با پروژه ما

در این پروژه:

- نمونه = یک تصویر از عدد دست‌نویس

- تعداد نمونه‌ها: $m \approx 1800$

- تعداد ویژگی‌ها: $n=64$ (۶۴ پیکسل)

پس ماتریس داده‌ها به صورت زیر است:

$$X_{m \times n}$$

که:

- هر ردیف = یک نمونه

- هر ستون = یک ویژگی

- f_{ij} = مقدار ویژگی j ام در نمونه i ام

چرا این مهم است؟

ما 64 ویژگی داریم.

اما بسیاری از این ویژگی‌ها به هم وابسته‌اند.

مثلاً اگر یک پیکسل روشن باشد، پیکسل‌های مجاور آن هم احتمالاً روشن هستند.

بنابراین می‌توان این 64 ویژگی را با تعداد کمتری ویژگی جدید که ترکیب خطی ویژگی‌های قبلی هستند تقریب زد.

به این ویژگی‌های جدید می‌گوییم:

مؤلفه‌های اصلی (Principal Components)

و این دقیقاً همان کاری است که PCA انجام می‌دهد.

مرحله 1

آشنایی با داده‌ها (بردار و فضای برداری)

برای اینکه درگیر مسائل جانبی مثل خواندن فایل نشویم، از یک دیتاست آماده استفاده می‌کنیم.

```
1 from sklearn.datasets import load_digits
2 digits = load_digits()
3 X = digits.data
4 y = digits.target
```

این داده‌ها شامل حدود 1800 تصویر از اعداد دست‌نویس هستند. هر تصویر 8×8 پیکسل است. یعنی هر تصویر 64 عدد دارد.

پس ماتریس X تقریباً ابعاد زیر را دارد:

$$1800 \times 64$$

یک تصویر نمونه را نمایش دهید :

```
1 import matplotlib.pyplot as plt
2 plt.imshow(X[0].reshape(8,8), cmap='gray')
3 plt.title(f"Label: {y[0]}")
4 plt.show()
```

این یعنی:

- هر سطر یک تصویر است.
- هر ستون یک ویژگی (یک پیکسل مشخص) است.

در گزارش خود توضیح دهید:

- این ماتریس از دید جبر خطی چه معنایی دارد؟
- هر سطر را می‌توان یک بردار در چه فضایی در نظر گرفت؟
- بُعد این فضا چیست؟
- آیا داده‌های شما کل فضای R^{64} را پر میکنند یا یک زیرمجموعه از آن هستند؟

مرحله 2

مرکزیت دادن به داده ها (انتقال مبدأ)

اگر داده‌ها را همین‌طور تحلیل کنیم، نتایج درستی نمی‌گیریم. پس اول باید آن‌ها را مرکز کنیم. یعنی چه؟؟؟

1. میانگین هر ستون را حساب کنید. این کار یک بردار 64 بعدی به شما می‌دهد.

2. این بردار میانگین را از تمام سطرهاى ماتریس کم کنید.

اگر ماتریس جدید را B بنامیم :

$$B = X - \text{mean}(X)$$

بعد از این کار، بررسی کنید میانگین ستون‌های B تقریباً صفر است.

تحلیل :

در گزارش توضیح دهید:

- چرا باید داده‌ها را مرکز کنیم؟
- اگر این کار را نکنیم، اولین مؤلفه اصلی چه جهتی را نشان می‌دهد؟
- از نظر هندسی چه اتفاقی می‌افتد؟

مرحله 3

ساخت ماتریس کوواریانس (ضرب ماتریسی)

حالا می‌خواهیم ببینیم داده‌ها در چه جهت‌هایی بیشتر پخش شده‌اند.
برای این کار ماتریس کوواریانس را می‌سازیم:

$$C = \frac{1}{m-1} B^T B$$

در اینجا:

- m = تعداد نمونه‌ها (تعداد سطرها)
- B = ماتریس داده‌های مرکز شده

ماتریس C یک ماتریس 64×64 است.

در گزارش توضیح دهید :

- آیا C متقارن است ؟ اگر بله ، چرا این ماتریس متقارن است؟
- ابعاد C را گزارش دهید.
- چرا ماتریس کوواریانس همیشه مثبت نیمه‌معین است؟
- متقارن بودن چه نتیجه مهمی درباره بردارهای ویژه می‌دهد؟

قطری سازی :

از نتایج سوالات بالا به ویژگی C پی بردید :

$$C = Q \Lambda Q^T$$

- توضیح دهید این تجزیه چه معنایی در PCA دارد ؟

(یادآوری: بردارهای ویژه ماتریس متقارن متعامد هستند.)

نکته :

(در برخی مراجع و توابع آماده مانند `numpy.cov` از مخرج $m-1$ استفاده می‌شود، اما در این پروژه برای سادگی محاسبات جبر خطی، همان m (یا مخرج $m-1$) هر دو قابل قبول هستند و تأثیری در جهت بردارهای ویژه ندارند.)

مرحله 4

تمرین عددی : الگوریتم تجزیه QR و رتبه ماتریس داده

قبل از اینکه سراغ مقادیر ویژه برویم، یک تمرین عددی انجام می‌دهیم.

الگوریتم QR روشی برای محاسبه مقادیر ویژه است.

در این روش:

1. ماتریس C را به صورت $C = QR$ تجزیه می‌کنیم.

2. سپس ماتریس جدید می‌سازیم : $C_1 = RQ$

3. این کار را تکرار می‌کنیم.

در هر مرحله ماتریس جدید با قبلی متشابه است و بنابراین مقادیر ویژه تغییر نمی‌کنند.

نیاز نیست الگوریتم QR را تا رسیدن به مقادیر ویژه نهایی برای ماتریس 64×64 ادامه دهید. فقط یک تابع بنویسید که یک یا چند مرحله از تجزیه (یعنی $C_1 = RQ$) را انجام دهد و با یک مثال عددی کوچک (مثلاً یک ماتریس متقارن 4×4) نشان دهید که ماتریس جدید با ماتریس قبلی متشابه است.

فقط یک تابع بنویسید و آن را روی چند ماتریس متقارن تصادفی تست کنید.

نکته مهم:

برای جلوگیری از ابهام حتماً از حالت reduced استفاده کنید :

```
Q, R = np.linalg.qr(B, mode='reduced')
```

• اگر B ابعاد $m \times n$ داشته باشد (در اینجا تقریباً 64×1797)

• در حالت reduced :

◦ Q ابعاد $m \times n$ دارد

◦ R ابعاد $n \times n$ دارد

در گزارش توضیح دهید :

- چرا ماتریس‌های حاصل در مراحل مختلف متشابه‌اند؟
- چرا ماتریس‌های متشابه مقادیر ویژه یکسان دارند؟
- ستون‌های Q چه ویژگی دارند ؟ آیا مستقل خطی هستند؟ چرا؟
- رتبه B را چگونه از R تشخیص می‌دهید ؟
- حداکثر رتبه B چقدر می‌تواند باشد؟
- ارتباط رتبه را با تعداد نمونه‌ها و ویژگی‌ها توضیح دهید.

مرحله 5

محاسبه مقادیر و بردارهای ویژه

اکنون برای ماتریس کوواریانس تصاویر از تابع زیر استفاده کنید:

```
numpy.linalg.eigh(C)
eigenvalues, eigenvectors = np.linalg.eigh(C)
```

این تابع مخصوص ماتریس‌های متقارن است.

⚠ خروجی eigh به صورت صعودی مرتب شده است.

شما باید آن را به صورت نزولی مرتب کنید:

```
idx = np.argsort(eigenvalues)[::-1]
eigenvalues = eigenvalues[idx]
eigenvectors = eigenvectors[:, idx]
```

پس از محاسبه:

- مقادیر ویژه را به ترتیب نزولی مرتب کنید.
- بردارهای ویژه را نیز مطابق همان ترتیب مرتب کنید.

در گزارش توضیح دهید :

- مقدار ویژه بزرگ چه معنایی دارد؟
- چرا بردار ویژه متناظر با بزرگ‌ترین مقدار ویژه مهم‌ترین جهت داده‌ها است؟
- این جهت از نظر هندسی چه چیزی را نشان می‌دهد؟
- چرا بردارهای ویژه متعامد هستند؟
- چرا تعامد در PCA حیاتی است؟

مرحله 6

Explained Variance

از مقادیر ویژه مرتب شده نزولی استفاده کنید:

```
explained_variance_ratio = eigenvalues / np.sum(eigenvalues)
cumulative_variance = np.cumsum(explained_variance_ratio)
```

- نمودار cumulative variance رسم کنید.
- برای حفظ 90% واریانس به چند مؤلفه نیاز است؟
- این عدد چه نسبتی از 64 است؟

مرحله 7

کاهش بعد (تغییر پایه)

حال فرض کنید می‌خواهیم داده‌ها را به جای 64 بعد، در 10 بعد نمایش دهیم.

1. اولین k بردار ویژه (مثلاً 10 تای اول) را انتخاب کنید.
2. آن‌ها را به صورت ستونی در ماتریس W قرار دهید.
3. داده‌ها را به فضای جدید تصویر کنید:

$$T = BW$$

ماتریس T نمایش جدید داده‌ها در فضای 10 بعدی است.

در گزارش توضیح دهید :

- چرا این کار در واقع «تغییر پایه» است؟
 - ستون‌های W چه زیرفضایی را می‌سازند؟
 - تصویر این تبدیل چیست؟
 - هسته این تبدیل چیست؟
 - قضیه رتبه یوچی را در اینجا توضیح دهید؟
- (تبدیل خطی $f(x) = W^T x$ را در نظر بگیرید که بردار 64 بعدی را به فضای k بعدی می‌برد.
تصویر (Image) و هسته (Kernel) این تبدیل خطی چه مفهومی در داده‌های ما دارند؟)

مرحله 8 تجسم در فضای دوبعدی

با $k=2$:

```
W2 = eigenvectors[:, :2]  
T2 = B @ W2
```

- Scatter plot رسم کنید
- هر نقطه را با رنگ متناظر با برجسب آن نمایش دهید.

در گزارش توضیح دهید:

- آیا کلاس‌ها جدا می‌شوند؟
- کدام اعداد بیشترین هم‌پوشانی را دارند؟
- آیا این با شهود شما از شباهت اعداد دست‌نویس سازگار است؟

مرحله 9

بازسازی داده ها و تحلیل خطا

حالا می‌خواهیم ببینیم چه مقدار اطلاعات از دست داده‌ایم.

چون بردارهای ویژه حاصل از eig متعامد و یکانی هستند:

$$W^T W = I$$

داده‌ها را بازسازی کنید :

$$\text{Breconstructed} = TW^T + \mu$$

(μ) همان بردار میانگینی است که در مرحله ۲ کم کرده بودند).

این باعث می‌شود تصاویر بازسازی شده دقیقاً شبیه اعداد اولیه شوند

کارها:

- خطای بازسازی (MSE) را محاسبه کنید.
- نموداری رسم کنید که نشان دهد با افزایش k خطا چگونه کاهش می‌یابد.
- یک تصویر نمونه را با $k=10$ ، $k=2$ ، و $k=30$ بازسازی و نمایش دهید.

هدف این است که ببینید کاهش بعد چه اثری دارد.

در گزارش خود بنویسید:

- چرا با افزایش k خطا کاهش می‌یابد؟
- کاهش بعد از دید هندسی چه معنایی دارد؟

(نیازی به اثبات رسمی قضیه Eckart-Young نیست؛ توضیح هندسی کافی است.)

مرحله 10

حالت $m < n$

به صورت تصادفی تصویر انتخاب کنید :

```
import numpy as np
indices = np.random.choice(len(X), 50, replace=False)
X_small = X[indices]
```

- مراحل مرکزسازی و محاسبه کوواریانس را تکرار کنید.
- مقادیر ویژه را حساب کنید.

در گزارش خود بنویسید :

- چند مقدار ویژه صفر (یا تقریباً صفر) است؟
- چرا $\text{rank}(B) \leq m$ است؟
- ارتباط با فضای پوچ چیست؟
- این موضوع چه ارتباطی با وابستگی خطی دارد؟

بخش اختیاری (نمره امتیازی)

یکی از موارد زیر :

1. ارتباط PCA و SVD را بررسی کنید.

یا

2. پروژه را روی دیتاست MNIST اجرا کنید.

نمره دهی

نمره	بخش
45	بیاده سازی صحیح مراحل 1-9
10	تجسم ها و نمودارها
20	تحلیل مفهومی عمیق (رتبه، یوجی، قطری سازی، تعامد)
10	تحلیل حالت $m < n$
5	توضیح بهترین تقریب رتبه k
10	کیفیت نگارش و ساختار گزارش
15+	بخش اختیاری

خروجی مورد انتظار ما چی هست ؟

گزارش شما باید شامل:

- توضیح ریاضی هر مرحله
- کد تمیز و مستند سازی شده
- نمودارها و تحلیل آنها
- پاسخ دقیق به سؤالات مفهومی
- جمع بندی نهایی :

«PCA از دید جبر خطی چیست؟»

سخن پایانی

در این پروژه شما فقط یک الگوریتم یاد نمی‌گیرید.

شما می‌بینید که :

- فضای برداری یک مفهوم انتزاعی نیست.
- تغییر پایه ابزار مهندسی داده است.
- تعامد تضمین پایداری عددی است.
- رتبه و فضای پوچ رفتار داده را تعیین می‌کنند.
- مقادیر ویژه جهت‌های پنهان داده را آشکار می‌کنند.

اگر این پروژه را عمیق انجام دهید،

نگاه شما به جبر خطی دیگر صرفاً مجموعه‌ای از قضایا نخواهد بود . . .

بلکه یک زبان برای فهم داده‌ها خواهد شد.

تنها نه ز رازِ دلِ من پرده برافتاد تا بود فلک، شیوهٔ او پرده‌داری بود
اوقاتِ خوش آن بود که با **دوست** به سر رفت باقی همه بی‌حاصلی و بی‌خبری بود . . .

One last project.

One more challenge.

One more step toward becoming the engineer you dream of being.

Finish it with passion.

The pages of this course may end here,

but the knowledge you earned will travel with you wherever life takes you.

Finish strong. Keep growing.

Last Dance . . . With **Love**

Nima... 